

Analyse de Données E-Commerce et Segmentation Client

Projet Final - Cloud Computing & Data Analytics

Tom Le Corre

Université Paris 1 Panthéon-Sorbonne
DU Data Analytics

18 février 2026

1. Contexte et Objectifs du Projet

Nous avons analysé un jeu de données massif issu d'une plateforme de e-commerce britannique pour optimiser la stratégie marketing.

Le Jeu de Données :

- **Source** : Transactions "Online Retail".
- **Volume Initial** : **541 909 lignes**.
- **Technologie** : Traitement distribué avec **PySpark** (API DataFrame).

Les 3 Objectifs :

- ① **Nettoyer** : Éliminer les données inexploitables (25% du volume).
- ② **Segmenter** : Créer des groupes clients homogènes (RFM).
- ③ **Prédire** : Identifier les "Gros Dépensiers" via le Machine Learning.

2. Nettoyage et Fiabilisation (Data Cleaning)

L'analyse exploratoire a révélé des incohérences majeures nécessitant un filtrage strict avant toute modélisation.

Étape de Nettoyage	Action PySpark	Impact
1. Données Brutes	<i>Chargement CSV</i>	541 909 lignes
2. Clients Manquants	<code>dropna(subset="CustomerID")</code>	- 135 080 lignes
3. Annulations	<code>filter(Quantity > 0)</code>	- 8 905 lignes
DONNÉES FINALES	Dataset Qualifié	397 924 lignes

Transformation :

- Conversion de InvoiceDate en format Temporel.
- Création de la variable TotalPrice (Quantité × PrixUnit).

3. Segmentation : L'Approche RFM

Nous sommes passés d'une analyse par transaction à une analyse par **Client Unique** (4 339 clients identifiés).

Les 3 Dimensions Marketing

- **R - Récence** : Nombre de jours depuis le dernier achat.
- **F - Fréquence** : Nombre total de commandes validées.
- **M - Montant** : Somme totale dépensée (Chiffre d'Affaires).

Préparation Technique (Crucial) :

- Usage de `VectorAssembler` pour fusionner les colonnes.
- Application de `StandardScaler` pour normaliser les écarts d'échelle (Jours vs Euros).

4. Analyse des Segments (Bisecting KMeans)

L'algorithme a identifié **3 profils types** au sein de la clientèle.

Cluster	Récence Moy.	Fréquence Moy.	Montant Moy.	Profil Business
Groupe 0 (Majorité)	246 Jours <i>Achat très ancien</i>	1.1 <i>Achat unique</i>	280 € <i>Faible valeur</i>	Clients Perdus / Inactifs <i>Besoin de relance</i>
Groupe 1 (Cœur de cible)	42 Jours <i>Achat récent</i>	3.8 <i>Régulier</i>	1 350 € <i>Bon panier</i>	Clients Réguliers <i>À fidéliser</i>
Groupe 2 (Elite)	6 Jours <i>Très Actifs</i>	19.5 <i>Intensifs</i>	10 500 € <i>Très haute valeur</i>	VIP / Champions <i>Traitement Premium</i>

5. Visualisation Stratégique des Segments

L'analyse des centroïdes nous permet de définir les actions prioritaires :

Les Perdus (Groupe 0)

- **Diagnostic** : Risque de Churn maximal.
- **Action** : Email de "Win-Back" avec promotion agressive (-20%).

Les Réguliers (Groupe 1)

- **Diagnostic** : Base stable mais potentiel inexploité.
- **Action** : Cross-selling (proposer des produits complémentaires).

Les VIP (Groupe 2)

- **Diagnostic** : 1% des clients font 30% du CA.
- **Action** : Programme de fidélité exclusif & frais de port offerts.

6. Prédiction Supervisée (Logistic Regression)

Objectif : Créer un modèle capable d'identifier automatiquement les clients à fort potentiel.

Configuration du Modèle

- **Cible (Label)** : 1 si le client est un "Gros Dépensier" (Seuil $> 500\text{€}$), sinon 0.
- **Features** : Variables RFM + Pays (encodé).
- **Protocole** : Séparation 70% Train (Apprentissage) / 30% Test (Validation).

Pourquoi la Régression Logistique ?

- Algorithme rapide sur les grands volumes de données (Big Data).
- Résultats facilement interprétables (probabilité d'appartenance à la classe).

7. Performance du Modèle

Résultats obtenus sur le jeu de test (données jamais vues par le modèle) :

Métrique	Résultat	Interprétation
Accuracy	98.2 %	Taux global de bonnes prédictions très élevé.
Précision	97.5 %	Peu de faux positifs (erreurs sur les VIP).
Rappel	95.0 %	Le modèle détecte la quasi-totalité des VIP.
F1-Score	0.96	Excellent équilibre global.

Conclusion Technique : Le modèle est fiable et robuste. Il peut être déployé en production pour scorer les nouveaux inscrits en temps réel.

8. Conclusion et Recommandations Finales

Bilan du Projet :

- **Technique** : Maîtrise de la chaîne PySpark complète (ETL → MLlib).
- **Business** : Segmentation claire en 3 groupes actionnables.

Pistes d'Amélioration :

- Intégrer des données démographiques (âge, genre).
- Tester des modèles non-linéaires (Random Forest) pour gagner les derniers points de précision.

Recommandation Clé

Prioriser l'effort marketing sur le **Groupe 0 (Les Perdus)** qui représente le plus gros volume de clients mais génère le moins de valeur actuelle.

Merci de votre attention.

Avez-vous des questions ?